

Содержание

1	Литературный обзор	2
1.1	Определения	2
1.2	Обзор алгоритмов сегментации	2
2	Глава 2	7
2.1	Набор данных	7
2.2	Алгоритмы сегментации в экспериментах	11
2.3	Метрики оценки качества сегментации	14

1 Литературный обзор

1.1 Определения

В рамках текущей работы, изображением размера $n = (n_1, n_2, n_3)$ будем называть отображение $I_n^m : P_3 \rightarrow G$, в котором элементы области определения $P \subset Z^3$ называются пикселями (вокселями), а $n_i \in N, i = 1, 2, 3$ и $(G, +)$ - аддитивная абелева группа [1].

Бинарной маской изображения I_n^m будем называть отображение $\tilde{I}_n^m : P_3 \rightarrow \{0, 1\}$, множество определения которого совпадает с множеством определения I_n^m .

TODO - add definition of множествами объекта и чувствительность метрик.

1.2 Обзор алгоритмов сегментации

В рамках данной работы рассматривается поведение сегментации изображения реконструкции в процессе томографии под контролем реконструкции. При этом выбор алгоритмов сегментации является важным шагом для дальнейшего проведения экспериментов.

С целью выбора алгоритма необходимо провести обзор доступных алгоритмов сегментации.

В научной периодике доступно большое количество публикаций на тему алгоритмов сегментации. Исследование [2] показало устойчивый рост количества ежегодно предложенных алгоритмов с 1995 года по 2006 года.

Систематизация и классификация доступных алгоритмов необходима для выбора наиболее подходящих для проведения экспериментов.

Хорошей отправной точкой в изучении доступных алгоритмов сегментации является рассмотрение схем их классификации.

Существует множество различных схем классификации алгоритмов сегментации. Например, часто используется классификация по одному признаку, такому как способ обработки изображения или степень участия человека в процессе сегментации [3].

В работе [4] также предложена схема обобщённой классификации,

объединяющая несколько одно-признаковых подходов в единую структуру.

В рамках проведённого литературного обзора поиск алгоритмов сегментации был проведен на основе их классификации по принципу работы.

Первым классом алгоритмов, встречающихся в литературе, является семейство пороговых алгоритмов.

Пороговые алгоритмы бинаризации выполняют классификацию вокселей изображения на основе заданного порогового значения интенсивности. Воксели с интенсивностью ниже порога относятся к фону, тогда как воксели с интенсивностью выше или равной порогу классифицируются как принадлежащие объекту.

Существует большое количество разнообразных пороговых алгоритмов, основные из которых изложены в работы [3].

Например, часть алгоритмов устанавливают порог глобально, другие - устанавливают его индивидуально для каждого пикселя.

Другим широко используемым подходом к сегментации является метод роста области (region growing), основанный на объединении вокселей с близкими характеристиками по мере распространения от заданных начальных точек [5].

Этот метод является полуавтоматическим, то есть он требует участия пользователя в процессе своей работы. В частности требуется ввести набор начальных точек.

В литературе встречается множество модификаций этого метода, включая автоматический вариант алгоритма, не требующий указания начальной точки [6].

Несмотря на такое множество модификаций, метод роста области достаточно трудно реализуем в контексте задачи сегментации под контролем реконструкции.

Полуавтоматический характер метода и ресурсоёмкость его автоматической модификации делают его непрактичным для использования в рамках данного исследования.

Следующим направлением, широко представленным в литературе, являются методы кластеризации. Схожесть формальных постановок

задач сегментации и кластеризации способствует применению кластеризационных алгоритмов в контексте сегментации.

В частности, алгоритмы K-means [7] и mean shift [8] нередко применяются при решении задач сегментации.

Применимость алгоритмов кластеризации к сегментации изображений реконструкции требует дополнительного анализа, поскольку реализация их вычислительно эффективных версий представляет собой нетривиальную задачу.

Представленные ранее классы алгоритмов во многом однородны по своей структуре и принципам работы. В то время как последующие группы объединяют существенно более разнородные методы, классифицированные по более общим признакам.

Такой группой алгоритмов являются методы на базе теории графов [9].

Принципы работы этих методов достаточно разнообразны. Некоторые работы применяют алгоритмы поиска разрезом в графе [10; 11], другие работы адаптируют алгоритм поиска максимального потока под задачу сегментации [12].

Также встречаются и нестандартные подходы к сегментации в этой группе алгоритмов.

Один из таких нестандартных подходов предложен в работе [13], где реализован алгоритм, концептуально близкий к Unseeded Region Growing, но основанный на представлении изображения в виде взвешенного графа.

Следующей группой являются вероятностные алгоритмы. Принцип работы методов в этой группе основан на некотором априорном предположении о распределении значений пикселей в рамках изображения.

На пример методы, изложенные в работах [14; 15] основаны на предположении, что значение пикселей объектов в изображении имеет распределение вейбюля.

Последней крупной группой алгоритмов, встречающейся в литературе, это методы на основе машинного обучения.

К алгоритмам на основе машинного обучения относятся как нейросетевые методы, применяемые в общей задаче сегментации изображений

[16; 17], так и подходы, адаптированные под изображения реконструкции в рамках томографии [18].

Также встречаются менее распространённые методы, включая клеточные нейронные сети [19] и отдельные примеры полуавтоматических алгоритмов, использующих классические модели, такие как метод опорных векторов [20; 21].

Некоторые выявленные в литературе методы не вписываются в описанные выше категории и базируются на оригинальных, зачастую уникальных подходах.

Алгоритмы этого типа представлены в небольшом числе работ и не формируют обособленного направления.

Одним из таких алгоритмов является Полуавтоматический SegMo [22], разработанный для сегментации изображений реконструкции индустриальной томографии.

Сам алгоритм достаточно сложный в реализации и требует активного участия пользователя, соответственно не подходит для исследования томографии под контролем реконструкции, однако авторы заявляют достаточно высокое качество сегментации на выходе.

Среди редких методов также встречаются алгоритмы на основе множеств уровня, использующие эволюцию поверхностей для выделения объектов в объёме. В работе [23] такой подход применён для трёхмерной сегментации сосудистой системы на данных магнитно-резонансной ангиографии.

В рамках литературного обзора были изучены пороговые алгоритмы, методы роста области, алгоритмы на основе кластеризации, теории графов, вероятностные подходы, а также методы, использующие машинное обучение и нестандартные оригинальные принципы.

Из большого разнообразия доступных алгоритмов была выбрана группа пороговых методов.

Причина выбора пороговых методов заключается в их высокой степени изученности. В литературе представлено множество работ, посвящённых их модификации, анализу и практическому применению, обладающих высокой цитируемостью.

Применение алгоритмов других групп в контексте томографии под

контролем реконструкции сопряжено с рядом ограничений.

Многие из них являются полуавтоматическими и требуют участия пользователя, что делает их непригодными для включения в итеративный процесс реконструкции.

Классы алгоритмов с высокой вычислительной сложностью, такие как методы кластеризации и алгоритмы на основе множеств уровня, затруднительно использовать в силу необходимости их повторного запуска на каждой итерации томографического сканирования.

Методы, основанные на нейронных сетях, требуют большого объёма размеченных данных, которые на текущий момент недоступны для рассматриваемой задачи.

Следующим этапом после выбора класса является формирование перечня конкретных алгоритмов, из которых будет производиться отбор для последующего эксперимента.

2 Глава 2

2.1 Набор данных

В целях исследования итеративного процесса томографии под контролем реконструкции с точки зрения качества сегментации необходимы следующие компоненты:

1. Набор данных, на которых проводятся эксперименты.
2. Алгоритмы сегментации.
3. Метрики для оценки качества сегментации.

Рассмотрим первую компоненту - входной набор данных.

Под набором данных, в рамках данной работы, подразумевается множество из n изображений $(I_m^n)_1, (I_m^n)_2, \dots, (I_m^n)_n$.

В целях простоты у всех изображения набора данных одинаковый размер.

Такое упрощение позволит сосредоточиться на вопросе останова в итеративном процессе томографии под контролем реконструкции, пропустив этап подбора параметров реконструкции отдельно для каждого изображения в наборе данных.

Основной целью работы является исследование правила останова в итеративной томографии под контролем реконструкции. Поэтому набор данных должен моделировать различные варианты соотношения между углами сканирования и угловой структурой изображений.

Большинство изображений в наборе данных являются синтетическими и были сгенерированы с помощью языка программирования Python.

Набор данных состоит из 8 изображений, сгруппированных по 2 на основе схожести моделируемой угловой структуры.

Все изображения набора данных имеют размер $n = (256, 512, 512)$.

Первая пара представляет собой два изображения реконструкции бетонных плит, предоставленные в работе [24].

Изображение "Бетон-1" содержит характерные горизонтально ориентированные дефекты, интерпретируемые как трещины. На рисунке 1

приведён один из срезов: слева реконструкция, справа — эталонная бинарная маска.




Рисунок 1 Срез 128 бинарной маски изображение "Бетон-1"

Изображение "Бетон-2" представляет собой бетонную плиту с дефектом типа раковина - пустое пространство внутри плиты.

На рисунке 2 приведен срез изображения реконструкции "Бетон-2" и соответствующий ему срез бинарной маски.




Рисунок 2 Срез 128 бинарной маски изображение "Бетон-2"

В этих изображениях стоит отметить преобладание объекта над фоном по количеству пикселей.

Следующей парой объектов в наборе данных являются синтетические изображения трёхмерной решётки, сформированной пересекающимися семействами параллельных плоскостей.

В одном случае решётка строго ортогональна координатным осям. Это изображение в дальнейшем обозначается как "Решётка". На рисунке 3 представлен срез её реконструкции и соответствующий срез эталонной бинарной маски.

Такой объект включён в набор данных как модель идеального случая: углы ориентации структур внутри объекта полностью совпадают с начальными углами сканирования в процессе томографии под контролем реконструкции.




Рисунок 3 Срез 128 бинарной маски изображение "Решетка"

Вторая решётка, обозначаемая как "Наклонная решётка" формируется по тому же принципу, что и предыдущая, но все её плоскости наклонены относительно координатных осей.

!!TODO добавить конкретные углы на которые конструкция наклонена!!

Соответствующие срезы реконструкции и эталона приведены на рисунке 4.

Данный объект моделирует случай, когда начальный набор углов сканирования не совпадает с ориентацией внутренних структур объекта. При этом число таких ориентаций ограничено: решётка состоит из трёх групп плоскостей, каждая из которых наклонена под фиксированным углом.

Ожидается, что при включении в процесс реконструкции проекций под соответствующими углами произойдёт резкое улучшение качества бинаризации.




Рисунок 4 Срез 128 бинарной маски изображения "Наклонная решётка"

2.2 Алгоритмы сегментации в экспериментах

С учётом необходимости многократного применения в процессе итеративной реконструкции, для экспериментов были выбраны пороговые алгоритмы, как простые, устойчивые и не требующие сложной настройки.

Основная идея пороговых алгоритмов достаточно проста.

Пусть дано изображение I_m^n размера $n = (n_1, n_2, n_3)$.

Выходом алгоритма будет сегментация \tilde{I}_m^n изображения I_m^n , совпадающая размером с исходным изображением.

Значение каждого пикселя сегментации \tilde{I}_m^n определяется по следующей формуле:

$$\tilde{I}_m^n(i, j, k) = \begin{cases} 1, & I_m^n(i, j, k) \geq t \\ 0, & I_m^n(i, j, k) < t \end{cases} \quad (1)$$

Соответственно в сегментации пиксель (i, j, k) классифицируется как объект если значение исходного изображения в этом пикселе имеет значение больше или равное некоторому порогу t , иначе этот пиксель

классифицируется как фон.

В зависимости от характера порога t выделяют глобальные и локальные пороговые алгоритмы.

В глобальном случае порог не зависит от пикселя, соответственно все пиксели сравниваются с одним значением порога.

Таковыми алгоритмами являются классический пороговый алгоритм и алгоритм Отсу.

В классическом пороговом алгоритме порог является параметром, соответственно он требует его априорной оценки.

Алгоритм Отсу [25] определяет оптимальное значение порога t , максимизируя межклассовую дисперсию:

$$\sigma^2(t) = \omega_0(t)\omega_1(t) [\mu_0(t) - \mu_1(t)]^2, \quad (2)$$

где $\omega_0(t)$ и $\omega_1(t)$ — вероятности (доли) фона и объекта при пороге t , а $\mu_0(t)$ и $\mu_1(t)$ — соответствующие средние значения интенсивности.

Алгоритм перебирает возможные значения t и выбирает то, при котором значение $\sigma^2(t)$ максимизируется.

Локальные пороговые алгоритмы определяют порог для каждого пикселя, соответственно порог t становится функцией от пикселя $t = t(i, j, k)$.

Распространенным локальным пороговым алгоритмом является метод Ниблэка [26].

Алгоритм Ниблэка определяет порог t для пикселя (i, j, k) по следующей формуле:

$$t(i, j, k) = \mu_r(i, j, k) + k\sigma_r(i, j, k) \quad (3)$$

где $\mu_r(i, j, k)$ и $\sigma_r(i, j, k)$ — среднее и среднеквадратичное отклонение интенсивности в окрестности r пикселя (i, j, k) .

В общем случае среднее и среднеквадратичное отклонение в окрестности r пикселя (i, j, k) рассчитываются по следующим формулам:

$$\mu_r(i, j, k) = \frac{1}{(2r+1)^3} \sum_{x=i-r}^{i+r} \sum_{y=j-r}^{j+r} \sum_{z=k-r}^{k+r} I_m^n(x, y, z) \quad (4)$$

$$\sigma_r(i, j, k) = \sqrt{\frac{1}{(2r+1)^3} \sum_{x=i-r}^{i+r} \sum_{y=j-r}^{j+r} \sum_{z=k-r}^{k+r} (I_m^n(x, y, z) - \mu_r(i, j, k))^2} \quad (5)$$

Соответственно окном является куб с длинной сторон $2r + 1$.

Проблемной частью формул 4 и 5 является ситуация, когда окно частично выходит за границы изображения.

В таких случаях применяются следующие стратегии обработки:

1. Обрезка окна по границам. Вычисления проводятся только по той части окна, которая полностью попадает внутрь изображения.
2. Задание фиксированного значения. За пределами изображения значения пикселей считаются равными фиксированной константе, например, нулю или среднему значению изображения.
3. Отражение по границе. Отсутствующие значения заполняются за счёт зеркального отражения пикселей относительно соответствующей границы изображения.

У каждой стратегии есть свои преимущества и недостатки. Её выбор зависит от характера входных изображений.

У классического алгоритма Ниблэка существует множество модификаций.

Таковыми модификациями являются, например, алгоритмы Сауволы [27] и Фансалкара [28].

В рамках данной работы выбран аффинный вариант алгоритма Ниблэка, описанный в работе [29].

Метод аффинного Ниблэка добавляет в уравнение 3 дополнительный параметр *beta*, который является глобальной оценкой шума.

$$t(i, j, k) = \mu_r(i, j, k) + \sigma_r(i, j, k) + \beta \quad (6)$$

Такая модификация является вычислительно эффективной так как к формуле добавляется константа, однако она добавляет дополнительный параметр.

Таким образом, итоговый набор алгоритмов, используемых в конвейере экспериментов, включает в себя:

1. Классический пороговый алгоритм
2. Алгоритм Отсу
3. Алгоритм аффинного Ниблека

Выбор данных алгоритмов обусловлен их высокой степенью изученности в литературе и активным применением в задачах компьютерной томографии.

Поскольку алгоритм бинаризации запускается на каждой итерации томографии под контролем реконструкции, его вычислительная эффективность напрямую влияет на общую скорость всего процесса.

В целях оценки результата работы алгоритмов сегментации необходим набор метрик, позволяющих сформировать наиболее целостное представление о полученных бинарных масках.

2.3 Метрики оценки качества сегментации

Последним необходимым элементом экспериментального конвейера является набор метрик оценки качества сегментации.

Метрики должны быть подобраны так, чтобы в совокупности охватывать ключевые аспекты качества бинарных масок — например, точность границ и степень перекрытия с эталоном.

Такой набор метрик должен выявлять различные типы ошибок и предоставлять более объективную оценку результата.

Хотя в области машинного обучения и компьютерного зрения существует множество метрик, не все из них применимы к задаче сегментации изображений.

Например, метрики, ориентированные на числовые значения, текстовые последовательности или графовые структуры, не учитывают пространственные особенности изображений и потому неинформативны в контексте сегментации.

Даже среди метрик, предназначенных для работы с изображениями, нередко встречается избыточность: несколько показателей могут

быть чувствительны к одним и тем же видам ошибок, и их совместное использование не даёт дополнительной информации.

В конвейер экспериментов требуется сформировать минимально необходимый набор метрик, который позволит обнаружить распространённые типы ошибок.

Чтобы выбрать такой набор метрик обоснованно, необходимо провести серию экспериментов на модельных данных.

Такие эксперименты позволят изучить поведение метрик при различных типах ошибок.

Для реализации таких экспериментов необходимы следующие шаги:

1. Собрать начальный набор метрик для исследования.
2. Определить набор ошибок, которые должны обнаружить метрики.
3. Сформировать модельные изображения для набора ошибок

Часть метрик для начального набора были найдены в работе [30]. Авторы данного исследования изложили распространённые метрики, применяемые в оценке качества сегментации изображений реконструкции в медицине.

Из таких метрик в начальный набор данных будут включены метрики DICE, Intersection Over Union (IOU), Mean Square Error (MSE).

Пусть даны эталонная бинарная маска $(\tilde{I}_m^n)_{gt}$ изображения и его сегментация $(\tilde{I}_m^n)_{seg}$.

Обозначим как $(\tilde{I}_m^n)_{gt} \cap (\tilde{I}_m^n)_{seg}$ множество пикселей, на которых значение сегментации и эталонной бинарной маски совпадают и равно 1:
 $(\tilde{I}_m^n)_{gt} \cap (\tilde{I}_m^n)_{seg} := |\{x \in P | (\tilde{I}_m^n)_{gt}(x) = (\tilde{I}_m^n)_{seg}(x) = 1\}|.$

Определим также $(\tilde{I}_m^n)_{gt} \cup (\tilde{I}_m^n)_{seg}$ как множество пикселей, на которых значение сегментации или эталонной бинарной маски равно 1:
 $(\tilde{I}_m^n)_{gt} \cup (\tilde{I}_m^n)_{seg} := |\{x \in P | (\tilde{I}_m^n)_{gt}(x) = 1 \vee (\tilde{I}_m^n)_{seg}(x) = 1\}|.$

Тогда метрика DICE определяется как следующей формулой:

$$DICE((\tilde{I}_m^n)_{seg}, (\tilde{I}_m^n)_{gt}) = \frac{2 \cdot |(\tilde{I}_m^n)_{gt} \cap (\tilde{I}_m^n)_{seg}|}{|(\tilde{I}_m^n)_{gt}| + |(\tilde{I}_m^n)_{seg}|} \quad (7)$$

где $|\tilde{I}_m^n|$ является мощностью множества пикселей, на которых маска (\tilde{I}_m^n) имеет значение 1: $|\tilde{I}_m^n| = |\{x \in P | (\tilde{I}_m^n)(x) = 1\}|$.

Метрика DICE принимает значения в отрезке от 0 до 1, где 0 - полное несовпадение изображений, а 1 - их полное совпадение.

Индекс DICE является одной из классических метрик перекрытия — класса метрик, которые измеряют степень пересечения двух множеств (в данном случае бинарных масок).

Другой растрасстраненной метрикой перекрытия является IOU, также известная как метрика Жаккарда. Она определяется слудующей формулой:

$$IOU((\tilde{I}_m^n)_{seg}, (\tilde{I}_m^n)_{gt}) = \frac{|(\tilde{I}_m^n)_{gt} \cap (\tilde{I}_m^n)_{seg}|}{|(\tilde{I}_m^n)_{gt} \cup (\tilde{I}_m^n)_{seg}|} \quad (8)$$

Аналогично метрики DICE, значения IOU находятся в отрезке от 0 до 1, где 0 - полное несовпадение изображений, а 1 - их полное совпадение.

Следующая метрика в начальном наборе - метрика Normalized Hausdorff - отличается от предыдущих двух по принципу сравнения.

Данная метрика основана не на площади перекрытия, а на расстоянии между множествами объекта в сегментации и в эталонной бинарной маске.

Чтобы определить метрику Normalized Hausdorff, определим расстояние между пикселем $x \in P$ и множеством $(\tilde{I}_m^n) = \{x | (\tilde{I}_m^n)(x) = 1\}$.

$$d(x, (\tilde{I}_m^n)) = \inf_{y \in (\tilde{I}_m^n)} (\sqrt{(x_0 - y_0)^2 + (x_1 - y_1)^2 + (x_2 - y_2)^2}) \quad (9)$$

Операясь на формулу 9 можно определить расстояние Хаусдорфа:

$$HD((\tilde{I}_m^n)_{seg}, (\tilde{I}_m^n)_{gt}) = \max(\sup_{x \in (\tilde{I}_m^n)_{seg}} d(x, (\tilde{I}_m^n)_{gt})) \quad (10)$$

Соответственно значением расстояния Хаусдорфа является максимум из минимумов расстояний от пикселя до множества объектов.

Определив все необходимые формулы можно определить метрику Normalized Hausdorff Distance:

$$NHD((\tilde{I}_m^n)_{seg}, (\tilde{I}_m^n)_{gt}) = 1 - \frac{\max(HD((\tilde{I}_m^n)_{seg}, (\tilde{I}_m^n)_{gt}), HD((\tilde{I}_m^n)_{gt}, (\tilde{I}_m^n)_{seg}))}{\sqrt{n_0^2 + n_1^2 + n_2^2}} \quad (11)$$

Максимальное значение расстояния Хаусдорфа в пределах изображения не превышает его диагонали, поэтому длина диагонали является разумным нормализующим коэффициентом.

Чем меньше значение расстояния Хаусдорфа, тем ближе бинарные маски друг к другу.

Для удобства интерпретации нормализованное расстояние вычитается из единицы, поэтому метрика Normalized Hausdorff Distance принимает значения от 0 (полное несовпадение) до 1 (полное совпадение масок).

Последней метрикой в начальном наборе является MSE - средне-квадратичное расстояние между пикселями сравниваемых масок.

$$MSE((\tilde{I}_m^n)_{seg}, (\tilde{I}_m^n)_{gt}) = \frac{1}{n_0 \cdot n_1 \cdot n_2} \sum_{x \in P} ((\tilde{I}_m^n)_{seg}(x) - (\tilde{I}_m^n)_{gt}(x))^2 \quad (12)$$

Таким образом, начальный набор метрик составлен из различных по принципу оценивания метрик.

Следующем шагом в формировании итогового набора метрик является составление набора эталонных изображений для оценки чувствительности начального набора к различным видам ошибок.

Будем рассматривать в качестве типовых ошибок рябь, соответствие границ объекта, выброс и ошибки при преобладании объекта над фоном.

Рябь будем определять как наличие фоновых пикселей, ошибочно попавших в область объекта.

Ошибка соответствия границ возникает в тех случаях, когда сегментированная область в целом совпадает с объектом, но границы объекта смещены относительно эталона.

Следующим типом ошибок является выброс - некоторое неболь-

шое количество пикселей ошибочно классифицированные как объект, при этом находящихся на расстоянии от области объекта.

Последней ситуацией, на которой будем проводить опыты над метриками, является преобладание объекта над фоном.

В такой ситуации некоторые метрики могут быть менее чувствительными к ошибкам так как в абсолютных цифрах большинство изображения является объектом. На пример это может привести к хорошей оценки нечувствительной метрикой если просто классифицировать все изображение как объект.

Модельные изображения, на которых будут проводиться эксперименты с метриками, приведены в рисунке 5.




Рисунок 5 Тестовое изображения для экспериментов по оценке чувствительности метрик; а — эталонная маска, б — тест «Рябь», в — тест «Соответствие границ», г — тест «Выброс», д — тест «Преобладание объекта над фоном», е — эталонная маска для теста «Преобладание объекта над фоном»

Собрав начальный набор метрик, определив типы ошибок и модельные изображения, можно провести эксперименты по оценке чувствительности метрик.

Эксперименты реализованы с помощью языка программирования Python с использованием библиотек numpy для работы с изображениями как с многомерным массивом, PIL для операций чтения и записи изображений в файловой системе, а также matplotlib для визуализации результатов.

Настройки экспериментов читаются с файла формата JSON, который представляет собой массив из объектов, описывающих эксперимент.

Каждый объект описание эксперимента содержит его название и пути к модельному и эталонному изображениям.

Программа сравнивает по каждой метрике модельные изображения с эталонными и записывает результат в таблицу, столбцы которой являются значениями метрик, а строки соответствуют экспериментам.

Заполнив таблицу с результатами программа выводит ее визуализацию в виде табличной тепловой карты.

Получившаяся в результате экспериментов тепловая карта представлена на рисунке 6.




Рисунок 6 Тепловая карта значений метрик для модельных изображений с различными типами ошибок. Цвет и числа отражают чувствительность метрик к отклонениям от эталона.

Сравнение значений метрик показывает, что IOU и DICE в целом демонстрируют схожее поведение на различных типах ошибок, однако IOU в большинстве случаев оказывается более чувствительной: она сильнее снижается при наличии отклонений от эталона. Соответственно в итоговый набор метрик имеет смысл включить IOU и исключить DICE.

Symmetric boundary dice показывает высокую чувствительность к ошибкам соответствия границ, ряби и ошибкам при преобладании объекта над фоном.

Метрика MSE реагирует на все виды ошибок, однако её показания в совокупности дублируются метриками IOU и Symmetric Boundary Dice,

что делает её избыточной в составе итогового набора.

Для ошибки типа выброс все метрики показывают сравнительно низкую чувствительность, однако наилучшие результаты наблюдаются у метрик IOU и Symmetric Boundary Dice.

В итоговый набор метрик включены IOU и Symmetric Boundary Dice. Первая представляет собой компактную и широко используемую метрику перекрытия, служащую ориентиром для оценки общей точности сегментации, а вторая — наиболее чувствительна к локальным погрешностям и искажениям границ.

Список литературы

1. Николаев Д. П. Методы и алгоритмы Хаф-анализа изображений в системах технического зрения : дис. ... канд. / Николаев Д. П. — 2023.
2. Zhang Y.-J. Advances in image and video segmentation. — IGI Global, 2006.
3. Wirjadi O. Survey of 3D image segmentation methods. — 2007.
4. Ханыков И. Классификация алгоритмов сегментации изображений // Известия высших учебных заведений. Приборостроение. — 2018. — Т. 61, № 11. — С. 978—987.
5. Adams R., Bischof L. Seeded region growing // IEEE Transactions on pattern analysis and machine intelligence. — 1994. — Т. 16, № 6. — С. 641—647.
6. Lin Z., Jin J., Talbot H. Unseeded Region Growing for 3D Image Segmentation. // ACM International Conference Proceeding Series. Т. 9. — Citeseer. 2000. — С. 31—37.
7. Segmentation and classification of lung tumor from 3D CT image using K-means clustering algorithm / P. Sarker [и др.] // 2017 4th international conference on advances in electrical engineering (ICAEE). — IEEE. 2017. — С. 731—736.
8. Comaniciu D., Meer P. Mean shift: A robust approach toward feature space analysis // IEEE Transactions on pattern analysis and machine intelligence. — 2002. — Т. 24, № 5. — С. 603—619.
9. Camilus K. S., Govindan V. A review on graph based segmentation // International Journal of Image, Graphics and Signal Processing. — 2012. — Т. 4, № 5. — С. 1.
10. Boykov, Kolmogorov. Computing geodesics and minimal surfaces via graph cuts // Proceedings Ninth IEEE international conference on computer vision. — IEEE. 2003. — С. 26—33.

11. Peng Z., Qu S., Li Q. Interactive image segmentation using geodesic appearance overlap graph cut // Signal Processing: Image Communication. — 2019. — Т. 78. — С. 159—170.
12. Topology cuts: A novel min-cut/max-flow algorithm for topology preserving segmentation in N-D images / Y. Zeng [и др.] // Computer vision and image understanding. — 2008. — Т. 112, № 1. — С. 81—90.
13. Felzenszwalb P. F., Huttenlocher D. P. Efficient graph-based image segmentation // International journal of computer vision. — 2004. — Т. 59. — С. 167—181.
14. Volumetric segmentation using Weibull E-SD fields / J. Hu [и др.] // IEEE Transactions on Visualization and Computer Graphics. — 2003. — Т. 9, № 3. — С. 320—328.
15. Ayed I. B., Hennane N., Mitiche A. Unsupervised variational image segmentation/classification using a Weibull observation model // IEEE transactions on Image processing. — 2006. — Т. 15, № 11. — С. 3431—3439.
16. A 3D convolutional neural network for volumetric image semantic segmentation / H. Lu [и др.] // Procedia Manufacturing. — 2019. — Т. 39. — С. 422—428.
17. Ха Л. М. Свёрточная нейронная сеть для решения задачи классификации // Труды Московского физико-технического института. — 2016. — Т. 8, 3 (31). — С. 91—97.
18. Milletari F., Navab N., Ahmadi S.-A. V-net: Fully convolutional neural networks for volumetric medical image segmentation // 2016 fourth international conference on 3D vision (3DV). — Ieee. 2016. — С. 565—571.
19. Liu C. J., Wu X. L. Industrial computerized tomography images segmentation based on cellular neural networks // Applied Mechanics and Materials. — 2011. — Т. 66. — С. 2228—2235.
20. Lang T., Sauer T. AI-Supported Segmentation of Industrial CT Data // 11th Conf. Ind. Comput. Tomogr. — Wels. 2022.

21. Semi-automatic Segmentation of MRI Brain Metastases Combining Support Vector Machine and Morphological Operators. / G. Gonella [и др.] // IJCCI. — 2019. — С. 457—463.
22. Nagai Y., Ohtake Y., Suzuki H. SegMo: CT volume segmentation using a multi-level Morse complex // Computer-Aided Design. — 2019. — Т. 107. — С. 23—36.
23. 3D volume segmentation of MRA data sets using level sets: image processing and display / A. A. Farag [и др.] // Academic radiology. — 2004. — Т. 11, № 4. — С. 419—435.
24. Wagner F., Maas H.-G. A Comparative Study of Deep Architectures for Voxel Segmentation in Volume Images // The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences. — 2023. — Т. 48. — С. 1667—1676.
25. A threshold selection method from gray-level histograms / N. Otsu [и др.] // Automatica. — 1975. — Т. 11, № 285—296. — С. 23—27.
26. Niblack W. An introduction to digital image processing. — Strandberg Publishing Company, 1985.
27. Sauvola J., Pietikäinen M. Adaptive document image binarization // Pattern recognition. — 2000. — Т. 33, № 2. — С. 225—236.
28. Adaptive local thresholding for detection of nuclei in diversity stained cytology images / N. Phansalkar [и др.] // 2011 International conference on communications and signal processing. — IEEE. 2011. — С. 218—220.
29. Николаев Д. П., Сараев А. А. Критерии оценки качества в задаче автоматизированной настройки алгоритмов бинаризации // Труды Института системного анализа Российской академии наук. — 2013. — Т. 63, № 3. — С. 85—94.
30. Taha A. A., Hanbury A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool // BMC medical imaging. — 2015. — Т. 15. — С. 1—28.